



Acemap 搜索增强-先导项目报告

1. 数据来源

- **GAKG 子集:**
 - **格式:** Parquet 文件 (`data/gakg_subset.parquet`)
 - **结构:** 包含学术概念的三元组数据 (Subject - Relation - Object)

2. 核心方法

2.1 搜索意图理解 ([intent.py](#))

- **方法:** 基于规则的自然语言处理
- **实现:** `IntentParser` 模块使用正则表达式 (Regex) 解析用户查询
 - **关键词提取:** 自动去除停用词 (如 "papers on", "research about")
 - **意图分类:** 识别排序意图 (如 "recent" -> 按时间排序) 和实体类型意图

2.2 知识图谱增强召回 ([recall.py](#))

- **方法:** 1-Hop 邻居扩展
- **流程:**
 - 实体链接:** 将用户关键词映射到 GAKG 图谱中的节点。
 - 邻居查找:** 检索该节点的一跳邻居 (Subject 或 Object), 按共现频率排序, 选取 Top-K 相关概念。
 - 混合检索:** 并行搜索“原始关键词”与“扩展概念”, 将结果融合。

2.3 客户端ui + 排序优化 ([search.py](#) & [app.py](#))

- **UI:** 使用streamlit构建交互界面
- **问题:** API 不支持直接按引用量或特定日期排序, 且单次返回数量受限。
- **解决方案:**
 - **批量获取:** 针对特定排序请求, 后台自动通过分页获取更大规模的候选集 (200-500)
 - **内存排序:** 在 Python 客户端对候选集进行基于 `cited_by_count` 或 `publication_date` 的快速排序

3. 运行方式

- **安装依赖:** `pip install -r requirements.txt`
- **启动应用:** `streamlit run app.py`